多部位时序与统计特征融合的人体活动识别研究

摘要

针对可穿戴人体活动识别中的传感器部位差异、缺失记录和类别不均衡问题，本文基于 PAMAP2 原始数据开展十二类监督分类研究。使用手腕、胸部和脚踝的加速度及角速度信号，经短缺失插值、长缺失分段和抗混叠降采样，形成 7410 个离线活动窗口。按照完整连续活动片段分组，将 5187 个窗口用于训练、2223 个用于测试，严格满足 7:3；仅在训练集内部进行三折分组交叉验证。比较统计特征逻辑回归、随机森林、早期融合 CNN 及部位时序与统计特征融合模型，并以交叉验证平均 Macro-F1 选择最终模型。四种主模型在固定测试集上的 Macro-F1 分别为 0.7998、0.9261、0.5693 和 0.8526。另使用随机森林开展单部位与移除部位对照，分析不同部位输入的作用。依据交叉验证选择的随机森林 在测试集上达到 0.9261 的 Macro-F1。本文提供固定划分、逐折预测和结果核验记录；同一受试者的不同片段可分布于训练与测试，故结论适用于已知活动内部的离线片段分类，不代表未见受试者或在线连续流识别能力。

关键词：人体活动识别；多传感器融合；分组交叉验证；独立测试；PAMAP2

Human Activity Recognition through Multi-Location Temporal and Statistical Feature Fusion

Abstract: This study compares twelve-class activity recognition on PAMAP2 using wrist, chest and ankle inertial signals. The 7,410 offline windows are split by complete activity segments into 5,187 training and 2,223 test windows (70/30). Three-fold group cross-validation uses only training data and selects the final model before testing. Logistic regression, random forests, an early-fusion CNN and a temporal/statistical fusion network obtain test macro-F1 scores of 0.7998, 0.9261, 0.5693 and 0.8526, respectively. Additional random-forest experiments compare sensor locations. Overlapping windows never cross partitions. Subjects may occur in both sets; results concern offline within-activity classification and do not establish unseen-subject or online recognition performance.

Key words: activity recognition; sensor fusion; group cross-validation; holdout evaluation; PAMAP2

1 数据描述与研究问题

可穿戴传感器通过不同身体部位的运动变化描述人体活动。同类信号会受到步态、动作幅度与佩戴差异影响，相邻重叠窗口还具有较强相关性。因此，切窗后直接逐窗随机划分可能将同一段信号同时放入训练集和测试集，使结果偏高。本文按完整录制片段划分，在满足课程要求的训练与测试比例 7:3 的同时，避免同段窗口跨越数据部分。

已有研究表明，卷积和循环网络可以用于可穿戴活动识别，但其适用性依赖数据处理和评价条件 [1, 2]。本文不把结构拼接作为新的架构贡献，而是比较统一协议下的四种轻量模型，考察统计特征与时序表示的差异、多部位输入的互补性，以及不同活动和个体测试片段的误差。这里的分组单位是连续活动片段，并非受试者；模型仍可能见过测试人员的其他活动片段。

1.1 数据来源与任务范围

PAMAP2 由九名受试者佩戴三组惯性测量单元和心率设备采集，完整数据包含十八种活动 [3]。Protocol 规定十二种活动，Optional 为额外活动；两者不应直接合并后仍称为相同的十二类任务。本文仅使用 Protocol，采用手腕、胸部和脚踝的三轴 $\pm 16g$ 加速度与三轴角速度，共十八个输入通道。官方说明推荐使用 $\pm 16g$ 加速度，以减少较小量程饱和和校准差异的影响 [4]。心率、磁力计、温度、重复量程加速度和无效姿态列不参与本实验。

受试者 109 的 Protocol 记录仅覆盖部分活动，故保留其审计记录但不纳入主实验。主实验采用 101–108 八名受试者，原始共 2864056 条逐时刻记录。其活动录制也不完全均衡，尤其 103 缺少四类活动；不能将所有个体当作均有十二类完整记录。表 1 与图 1 给出处理后的覆盖情况。原始文件、压缩包及处理后数组均记录 SHA-256，便于追溯数据版本。

表 1: 主实验数据覆盖与缺失情况

受试者	原始记录数	活动数	窗口数	缺失率（%）
101	376417	12	956	0.291
102	447000	12	1008	0.415
103	252833	8	667	0.162
104	329576	10	886	0.357
105	374783	12	1044	0.341
106	361817	11	957	0.252
107	313599	11	890	0.298
108	408031	12	1002	0.442

注：缺失率按所选十八个传感器列在该受试者全部原始记录中的缺失元素比例计算；活动数为切窗后有样本的类别数。

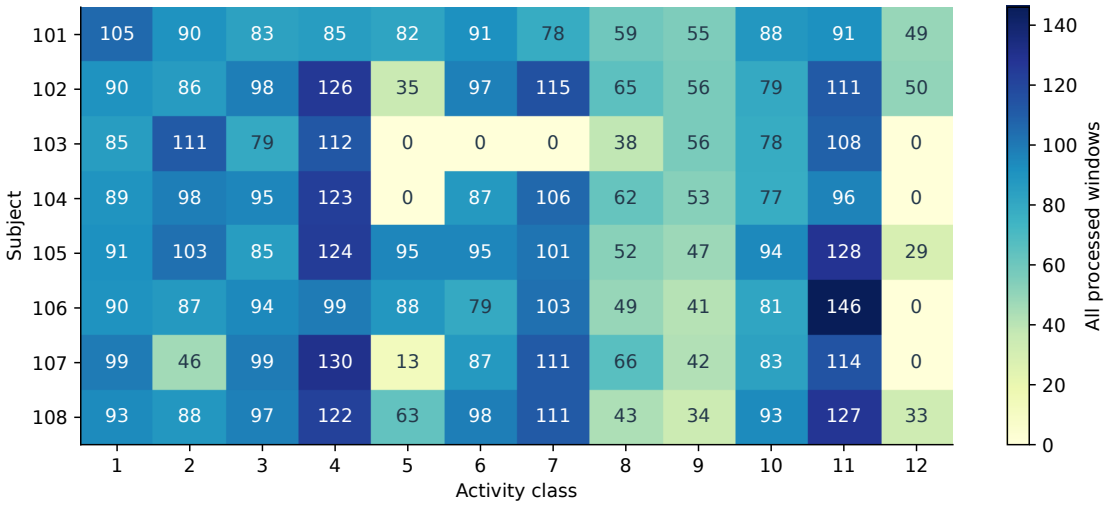


图 1: 各受试者与活动类别的窗口数量。零值表示对应活动未产生可用窗口。

1.2　预处理与窗口构建

首先按受试者分别处理文件，在活动标签变化、时间戳增量超过 0.03 s 或不递增的位置切开记录；不属于规定十二类的过渡标签不保留。任一所选通道若出现超过五十个原始采样点的连续缺失，则排除对应区间并再次切分；不足该阈值的缺失只在当前连续活动段内部插值，段边缘采用最近有效值。该处理不跨越受试者、活动变化或长缺失区间。

在原始 100 Hz 记录上使用多相低通滤波降采样至 50 Hz[5]，每窗包含 256 点，持续 5.12 s，步长为 128 点，即相邻窗口重叠 50%。不足完整窗口的尾部不填充，最终获得 $7410 \times 18 \times 256$ 的信号张量。本文将同一连续活动段产生的全部窗口绑定到同一数

据部分，因此重叠窗口及同段插值、滤波所使用的信号不会跨越训练与测试。

这里使用标注边界保留纯活动窗口，属于离线识别基准。插值和零相位滤波还会利用同一活动段内前后的信号，因此不能将结果解释为不使用未来信息的在线系统性能。传感器减少实验统一使用三部位共同可用的窗口，以保持样本一致；它并不估计单传感器在实际部署中可能额外保留的数据量。

2 模型描述

2.1 统计特征与标准化

每个信号通道提取均值、标准差、最小值、最大值、均方根、去均值频谱的谱熵和主频七项特征，六个通道合计四十二维。另对加速度与角速度的三轴模长各提取均值、标准差、最小值和最大值，合计八维。因此每个部位有五十维，三个部位拼接得到 $\boldsymbol{f} \in \mathbb{R}^{150}$。设去均值频谱功率为 P_k，并将直流项置零，则谱熵为

$$H = -\sum_{k} p_k \log(p_k + \epsilon), \qquad p_k = \frac{P_k}{\max(\sum_j P_j, \epsilon)}. \tag{1}$$

所有统计特征仅依赖单个窗口，不从完整数据拟合变换。对于需要标准化的模型，以当前训练部分估计均值和标准差：

$$z_j = \frac{f_j - \mu_j^{\text{train}}}{\max(\sigma_j^{\text{train}}, 10^{-6})}. \tag{2}$$

神经网络信号输入另按通道在训练窗口和时间轴上估计标准化参数。验证集或测试集不参与这些参数的估计。

2.2 逻辑回归与随机森林

逻辑回归使用多类 Softmax 线性分类器，以 L2 正则化限制参数规模，固定 $C = 1$、最大迭代数 2000，类别权重采用训练样本的平衡权重。它用于检验统计特征是否已经足以形成具有区分度的表示。

随机森林通过多棵决策树集成建模非线性关系 [6]。本实验固定 240 棵树、每叶最少两个样本、每次分裂考虑约 $\sqrt{d}$ 个特征，并采用各自助样本内部的平衡类别权重。不设最大树深度，不进行标准化。单部位和移除部位实验保持树数等设置相同，只改变输入的部位特征列。由于维度 d 随之变化，默认分裂候选数也变化，因此这是固定训练规则下的系统对比，而非只改变一个物理传感器的完全因果实验。

2.3 早期融合卷积网络

早期融合 CNN 将十八通道同时送入卷积编码器。三层卷积的通道数为 $18 \to 24 \to 48 \to 64$，核宽为 $7, 5, 3$，步长均为 2，每层后接批归一化和 ReLU。时间长度由 256 降至 128、64、32，随后执行全局平均池化、丢弃率 0.25 的 Dropout 和十二类线性分类。该模型参数量为 19052，不使用人工统计特征。

2.4 部位时序与统计特征融合

融合模型为每个部位建立一个独立编码器。每个分支仅接收该部位六通道信号，三层通道数为 $6 \to 16 \to 24 \to 32$，卷积核、步长与早期融合网络一致。每个分支池化后得到三十二维表示。统计特征分支以标准化的一百五十维向量为输入，通过 $150 \to 64$ 的全连接层、ReLU 和 Dropout，得到六十四维表示。

$$\boldsymbol{h}_s = \mathrm{GAP}(E_s(\boldsymbol{X}_s)) \in \mathbb{R}^{32}, \quad s \in \{w, c, a\}, \tag{3}$$

$$\boldsymbol{h}_f = \mathrm{Dropout}(\mathrm{ReLU}(W_f \boldsymbol{z} + b_f)) \in \mathbb{R}^{64}, \tag{4}$$

$$\boldsymbol{u} = [\boldsymbol{h}_w; \boldsymbol{h}_c; \boldsymbol{h}_a; \boldsymbol{h}_f] \in \mathbb{R}^{160}. \tag{5}$$

最终通过 $160 \to 64 \to 12$ 的分类头输出类别。模型参数量为 35868。局部分支保留不同部位的表征，统计特征提供动作姿态与幅度等窗口信息；能否带来额外收益需要根据实验判断。该结构没有显式注意力权重，不能把随机森林消融的成绩解释为神经网络学得的部位重要性。

两个神经网络都使用 AdamW，学习率 10^{-3}、权重衰减 10^{-4}、批量大小 128，固定训练二十五轮。损失为按训练类别计数平方根倒数加权的交叉熵，权重均值归一化为 1，并把梯度范数截断为 5。只使用 CPU，固定随机种子与确定性计算；运行环境为 Python 3.14.3、PyTorch 2.12.0+cpu、scikit-learn 1.9.1。

3 实验协议与评价指标

3.1 固定 7:3 划分与片段隔离

本次采用固定留出测试集，而非以留一受试者验证替代 7:3 划分。全部 7410 个窗口均保留：训练集 $N_{\mathrm{train}} = 5187$，测试集 $N_{\mathrm{test}} = 2223$，满足

$$\frac{N_{\mathrm{train}}}{N_{\mathrm{train}} + N_{\mathrm{test}}} = 0.7, \qquad \frac{N_{\mathrm{test}}}{N_{\mathrm{train}} + N_{\mathrm{test}}} = 0.3. \tag{6}$$

分组单位为预处理得到的完整连续活动段，共 106 段。每段只对应一个受试者和一种活动，且已在标签变化、时间跳变及长缺失处断开。由于同段窗口重叠且共享插值、滤

波上下文，整段必须绑定到同一数据部分。该约束同时用于训练与测试隔离，以及交叉验证各折之间的隔离。

仅根据活动标签、片段编号及窗口数量进行分组分配，不使用信号取值、模型预测或成绩。分配程序采用混合整数约束 [8]，要求测试集 2223 窗口、三个训练验证折各 1729 窗口、每部分均覆盖十二类；在约束下尽量减小各类数量相对目标比例的偏差。限时求解所得可行划分经过独立断言核验，不宣称类别比例偏差已达到全局最优。各类别因完整片段约束，比例不必分别等于 7:3，精确比例针对全部窗口。划分保存在逐窗口清单 `split_assignments.csv` 并固定哈希，复现实验直接复用该清单，不反复生成划分后挑选高分。

表 2: 固定数据划分；后三行是训练集内部的三个互斥验证子集

数据部分	完整片段数	窗口数	占全部窗口（%）
训练集	73	5187	70.00
测试集	33	2223	30.00
训练内第 1 验证折	25	1729	23.33
训练内第 2 验证折	23	1729	23.33
训练内第 3 验证折	25	1729	23.33

注：三个验证子集合计为训练集，各为训练集的三分之一；它们不是额外数据。

表 3: 训练、测试与交叉验证各验证折的类别覆盖

活动	训练集	测试集	验证折 1	验证折 2	验证折 3
躺卧	538	204	181	174	183
坐	495	214	157	174	164
站立	533	197	178	182	173
步行	675	246	256	222	197
跑步	265	111	88	95	82
骑车	439	195	170	95	174
北欧式行走	503	222	115	209	179
上楼	244	190	95	53	96
下楼	251	133	91	93	67
吸尘	486	187	159	165	162
熨烫	647	274	210	218	219
跳绳	111	50	29	49	33

需要区分两种隔离：本次测试片段未参与模型拟合、标准化或模型选择，但训练与测试可能包含同一个人的不同片段。这不能证明对未见人员的推广能力。此外，这批公开数据在此前的留一受试者实验中已被评价；本次是因课程比例要求而重新固定的协议，并非历史上从未使用的新外部测试数据。旧协议配置、代码与结果另行留档，不与本次分数合并或直接比较。

3.2 仅在训练集内的三折分组交叉验证

设训练集分为互斥的片段组 V_1, V_2, V_3，每组包含 1729 个窗口。第 k 折使用 $T_k = \mathcal{D}_{\text{train}} \setminus V_k$ 的 3458 个窗口训练，在 V_k 上验证。通过固定折映射实现三折交叉验证 [7]，每个训练窗口恰好验证一次，2223 个测试窗口不出现在任何一次交叉验证的训练或验证部分。

选择三折是因为跳绳活动总共只有四个独立片段，留出一个用于测试后，训练集仅剩三个片段；三折能够使每个验证折均保留跳绳及其他十一类活动。若强行做五折分组验证，至少两个验证折将缺少跳绳。所有模型共享同一份冻结划分，避免不同配置使用不同测试难度。

每次拟合时，逻辑回归的标准化器仅在当前训练折拟合；神经网络的信号、统计特征标准化以及类别权重也只由当前训练折估计。结构、树数、窗口长度及优化参数沿用预设值；两个网络在每个交叉验证折和最终训练中均固定二十五轮，不使用测试或验证成绩选择轮数，也不额外调参。基础种子为 42，三个交叉验证折分别使用 43、44、45，最终训练使用 42。

四种主模型依据三个验证折固定十二类 Macro-F1 的算术平均值选择，传感器对照不进入最终模型候选集合。选择结果及各验证成绩哈希在测试预测产生前保存。随后对十个预先列明的配置分别在全部 5187 个训练窗口上重新拟合，在相同 2223 个测试窗口上评价一次；最终展示模型仍按先前的交叉验证选择，不按测试排名更换。共进行 $10 \times 3 = 30$ 次交叉验证拟合和十次最终拟合。

3.3 指标定义与统计范围

主指标为固定十二类的 Macro-F1：

$$F_{1,c} = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad F_1^{\text{macro}} = \frac{1}{12}\sum_{c=1}^{12} F_{1,c}. \tag{7}$$

同时记录 Accuracy 与宏平均召回率，分母为零时对应类别取零。交叉验证报告三个折的算术平均值与样本标准差：

$$\bar{F}_{\text{CV}} = \frac{1}{3}\sum_{k=1}^{3} F_k, \qquad s_{\text{CV}} = \sqrt{\frac{1}{2}\sum_{k=1}^{3}(F_k - \bar{F}_{\text{CV}})^2}. \tag{8}$$

交叉验证分数用于比较训练阶段表现，测试分数仅由留出测试窗口计算，两者分别报告。三个折的训练数据相互重叠，标准差描述折间波动，不是独立测试的置信区间。

个体测试片段可能只包含部分活动，故描述性个体图使用该人在测试中实际出现类别的 Macro-F1。它与固定十二类的总体指标不同，不用于最终模型选择。不将重叠窗口当作独立统计样本，本次不根据窗口数量计算显著性检验或夸大人群推断。

4 实验结果与分析

4.1 交叉验证与主模型对比

表 4: 训练集内部三折交叉验证的固定十二类 Macro-F1

模型	验证折 1 F1	验证折 2 F1	验证折 3 F1	均值
逻辑回归	0.9116	0.8473	0.8901	0.8830
随机森林	0.9026	0.9189	0.9101	0.9105
仅手腕	0.8003	0.8301	0.8142	0.8149
仅胸部	0.7699	0.8541	0.8128	0.8123
仅脚踝	0.7135	0.7708	0.7715	0.7519
移除手腕	0.8386	0.8249	0.8269	0.8301
移除胸部	0.8831	0.8651	0.8723	0.8735
移除脚踝	0.8705	0.9160	0.8856	0.8907
早期融合 CNN	0.8147	0.7149	0.8508	0.7935
部位与统计融合	0.9310	0.8509	0.9114	0.8978

表 5: 主模型的训练交叉验证与固定 30% 测试集结果

模型	训练 CV F1 均值 ± SD	测试 Accuracy	测试 F1
逻辑回归	0.8830 ± 0.0327	0.8241	0.7998
随机森林	0.9105 ± 0.0082	0.9213	0.9261
早期融合 CNN	0.7935 ± 0.0704	0.5879	0.5693
部位与统计融合	0.8978 ± 0.0418	0.8444	0.8526

注：F1 均固定十二类；SD 为三个验证折的样本标准差。测试成绩来自同一组 2223 个窗口。

依据训练集三折验证的平均 Macro-F1，选定随机森林作为最终展示模型，其验证均值为 0.9105，样本标准差为 0.0082。在冻结的 2223 个测试窗口上，该模型 Accuracy 为 0.9213，Macro-F1 为 0.9261。选择记录在本轮测试预测生成前写入，最终模型没有根据测试排名更换。

四个预设主模型中，测试 F1 数值最高的是随机森林（0.9261）。融合模型相对随机森林的测试 F1 差值为 -7.35 个百分点。表中交叉验证标准差描述三个验证折之间的波动，既不是测试分数的置信区间，也不能用来直接断言显著性。训练 CV 与测试分数的差异受到片段组成和最终训练样本量变化影响。

早期 CNN 的验证均值为 0.7935，测试 F1 为 0.5693，融合模型对应为 0.8978 与 0.8526。神经网络在当前固定设置下的折间与测试波动较大，说明不能只依据训练损失下降判断泛化质量。需要额外划分和初始化复验，才能进一步区分训练设置与片段组成的影响。

融合与早期 CNN 的表示方式和参数量均不同，且未单独删除统计分支或保持等参数量，因此现有对比评价的是完整系统，不能将差异全部归因于多分支结构。

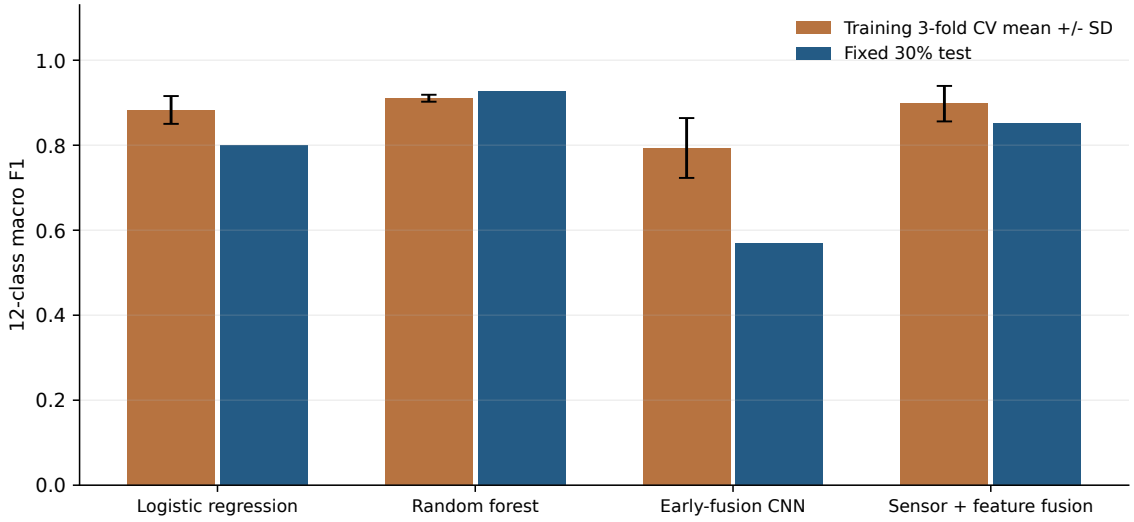


图 2: 训练交叉验证均值与最终测试成绩；误差线仅表示验证折间标准差。

4.2 传感器部位对比

表 6: 固定随机森林规则下的部位输入对照

部位输入	训练 CV F1 均值 ± SD	测试 Accuracy	测试 F1
仅手腕	0.8149 ± 0.0149	0.7323	0.7497
仅胸部	0.8123 ± 0.0421	0.7940	0.7690
仅脚踝	0.7519 ± 0.0333	0.6946	0.7107
移除手腕	0.8301 ± 0.0074	0.7962	0.8132
移除胸部	0.8735 ± 0.0091	0.9118	0.9162
移除脚踝	0.8907 ± 0.0232	0.8673	0.8766
随机森林	0.9105 ± 0.0082	0.9213	0.9261

单部位实验中，仅胸部的测试 Macro-F1 最高，为 0.7690。完整三部位随机森林为 0.9261；移除实验中移除手腕的测试 F1 最低，为 0.8132。各配置使用完全相同的训练、验证和测试窗口；仅改变输入部位的统计特征列。不同部位同时包含姿态、局部运动和个体习惯等信息，训练 CV 排名与测试排名可能不同，这些成绩不构成神经网络分支重要性的因果证明。

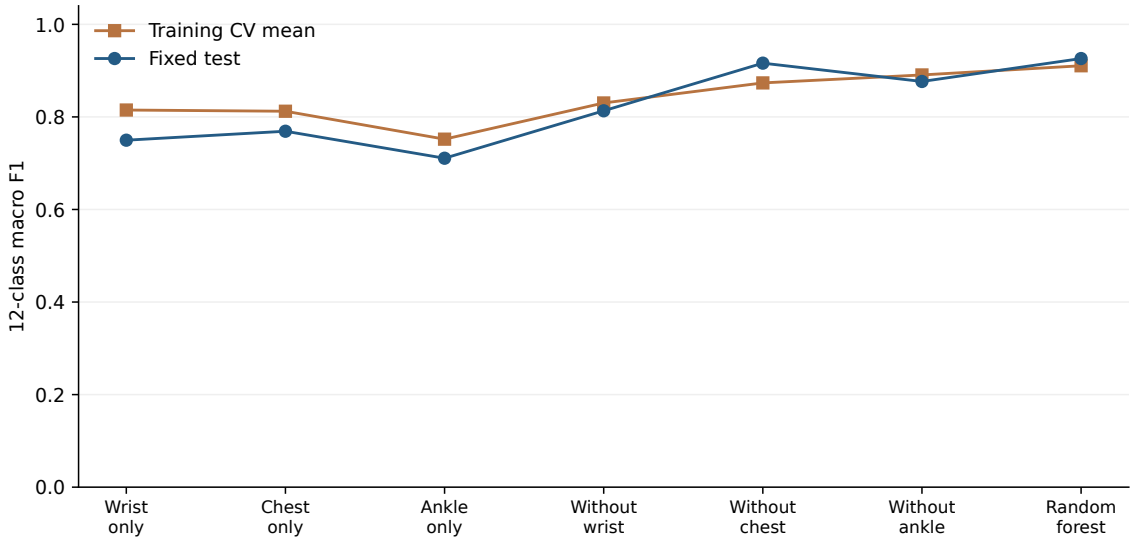


图 3: 同一划分下的部位实验，分别显示训练交叉验证均值和测试 F1。

4.3 类别与个体测试片段差异

融合模型测试 F1 较低的三个类别为站立（0.5706）、坐（0.7003）、熨烫（0.7391）。不同类别的片段数量、训练覆盖及动作特征不同，不能仅凭总体成绩解释所有类别。混淆矩阵按真实类别逐行归一化；矩阵对角线为召回率，与表中的逐类 F1 定义不同。

表 7: 固定测试集的活动窗口数与逐类 F1

编号	活动	测试窗口数	逻辑回归	随机森林	融合模型
1	躺卧	204	0.8861	0.9681	0.8845
2	坐	214	0.6953	0.8397	0.7003
3	站立	197	0.5928	0.8115	0.5706
4	步行	246	0.9775	0.9755	0.9775
5	跑步	111	0.5488	0.9577	0.9358
6	骑车	195	0.9361	0.9793	0.8904
7	北欧式行走	222	0.9052	0.9863	0.9306
8	上楼	190	0.9446	0.9514	0.9570
9	下楼	133	0.9236	0.9466	0.9368
10	吸尘	187	0.7963	0.8709	0.7885
11	熨烫	274	0.7938	0.8791	0.7391
12	跳绳	50	0.5974	0.9474	0.9200

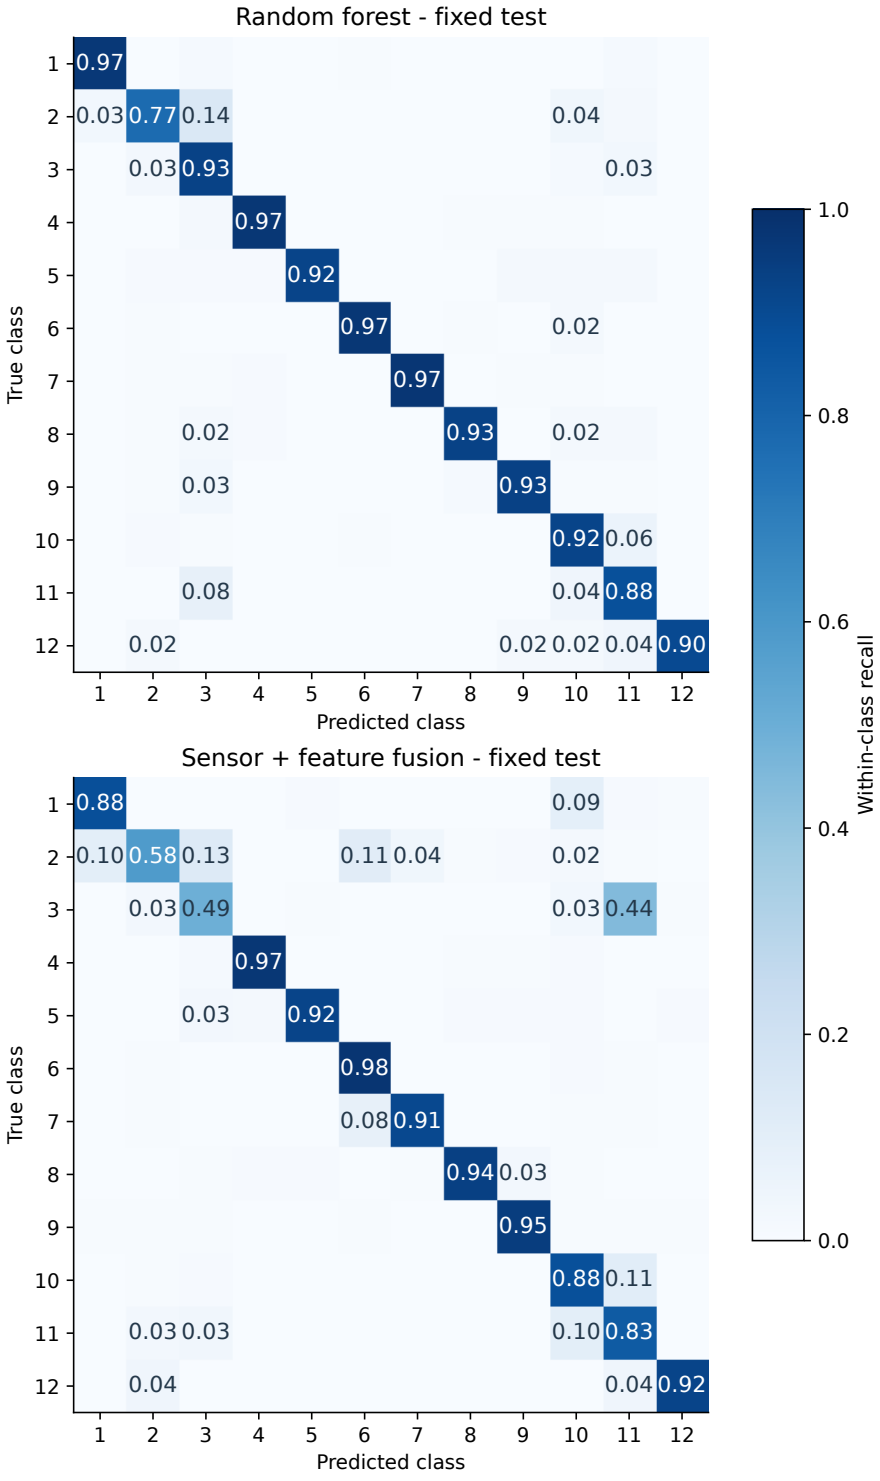


图 4: 固定测试集的行归一化混淆矩阵；类别编号对应表7。

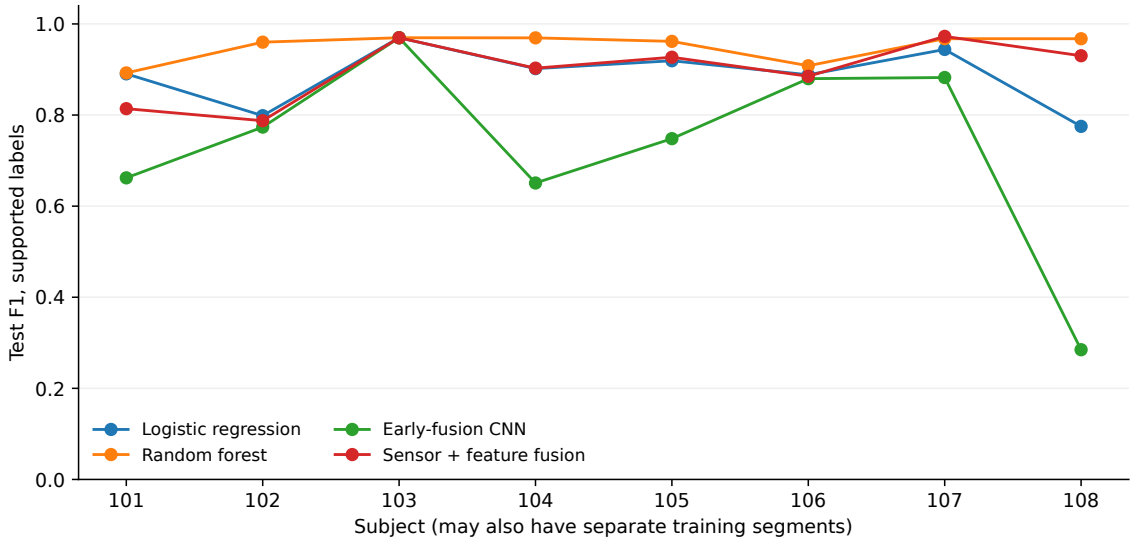


图 5: 各人测试片段的实际出现类别 F1；同一人的其他片段可能参与训练。

按测试窗口中的实际出现类别计算，融合模型在受试者 102 的测试片段上 F1 最低（0.7875），在受试者 107 上最高（0.9727）。部分个体的测试类别较少，应结合活动覆盖理解这些分数。相同受试者的其他片段可能用于训练，此图是固定测试集内部的描述，不能解释为对全新受试者的迁移性能。

4.4 结果核验与模型展示

分析程序读取四十次拟合保存的窗口索引、真实标签、预测、片段编号及配置哈希，验证训练与测试窗口数、片段隔离及类别覆盖，检查每个训练窗口恰好被交叉验证验证一次，且测试窗口从未进入交叉验证。再根据预测重新计算全部指标，与训练记录逐项比对。保存模型重新加载后还需复放相应验证或测试窗口，确认预测完全一致。图表与表格从这些记录生成，不手动填写预期成绩。

展示模型直接导出交叉验证所选模型在 70% 训练集上拟合的已评价版本，保留 30% 测试片段隔离，不再用全部数据重训。另从各测试类别按固定索引分位点选两个窗口，共二十四个样本回放，选样不按预测正确与否筛选。少量演示仅说明运行过程，正式测试成绩以全部 2223 个窗口为准。

5 局限与结论

本实验覆盖八名受试者、固定佩戴位置和受控活动，存在类别不均衡及部分个体缺少活动的情况。完整片段分组阻止重叠窗口跨集合，但没有隔离人员或整个采集会话，因此仍可能利用同人特征和相同采集条件，不能解释为未见受试者泛化。仅使用一次固定 7:3 划分及一个基础种子，未覆盖所有划分与初始化波动。三个训练验证折

的统计量也不足以支持广泛人群中的显著性结论。

已知标注边界、离线插值和零相位滤波限制了结果的适用范围，本实验不评价过渡检测、未知活动、实时延迟或传感器故障时的在线鲁棒性。融合网络的统计分支未单独消融，不同模型的容量与输入表示亦不同。最大计算预算下的固定二十五轮不代表网络已达到最优。此前对同批数据的历史实验意味着本次留出集不能替代全新的外部数据验证。

本文按照训练与测试严格 7:3、仅训练集内部交叉验证的要求，建立可追溯的十二类活动识别流程。依据三折分组验证选择的随机森林，验证平均 Macro-F1 为 0.9105，最终测试 Macro-F1 为 0.9261，Accuracy 为 0.9213。实验同时保留完整系统、传感器配置与逐类别误差对比。未来可在额外受试者、不同会话及多种子划分上复验，并研究在线分段及质量自适应融合。

参考文献

[1] ORDÓÑEZ F J, ROGGEN D. Deep convolutional and LSTM recurrent neural networks for multimodal wearable activity recognition[J]. Sensors, 2016, 16(1): 115. DOI: 10.3390/s16010115.

[2] HAMMERLA N Y, HALLORAN S, PLOETZ T. Deep, convolutional, and recurrent models for human activity recognition using wearables[EB/OL]. arXiv:1604.08880, 2016. https://arxiv.org/abs/1604.08880.

[3] REISS A. PAMAP2 Physical Activity Monitoring[DS/OL]. UCI Machine Learning Repository, 2012[2026-10-18]. DOI: 10.24432/C5NW2H.

[4] REISS A, STRICKER D. PAMAP2 Dataset: Physical Activity Monitoring, README and data documentation[EB/OL]. 2012[2026-10-18]. https://archive.ics.uci.edu/ml/machine-learning-databases/00231/readme.pdf.

[5] SCIPY DEVELOPERS. scipy.signal.resample_poly[EB/OL]. [2026-10-18]. https://docs.scipy.org/doc/scipy/reference/generated/scipy.signal.resample_poly.html.

[6] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45: 5–32. DOI: 10.1023/A:1010933404324.

[7] SCIKIT-LEARN DEVELOPERS. PredefinedSplit: predefined training and validation folds[EB/OL]. [2026-10-26]. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.PredefinedSplit.html.

[8] SCIPY DEVELOPERS. scipy.optimize.milp: mixed-integer linear programming[EB/OL]. [2026-10-26]. https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.milp.html.